



INSTITUTO FEDERAL DA PARAÍBA - IFPB

Unidade Acadêmica de Informação e Comunicação

Mestrado Profissional em Tecnologia da Informação

Disciplina: **Ciência de Dados**

Docente: Damires Souza e Alex Cunha

Período: 2026.1

Equipe/responsável: Rodrigo de Queiroz Gonçalves Velez

Caio Jordan de Lima Maia

Planejamento para projeto de Ciência de Dados

1. Compreensão do negócio/domínio do problema

- i. **Contextualização:** escreva um ou dois parágrafos apontando o **contexto do problema/domínio de aplicação/situação da empresa**.

As Doenças Crônicas Não Transmissíveis (DCNT), como doenças cardiovasculares, diabetes, câncer e doenças respiratórias crônicas, entre outras, são responsáveis por um percentual considerável de mortes no Brasil. A análise destes dados em nível municipal é importante para apoiar políticas públicas na área da saúde, permitindo identificar desigualdades regionais e proporcionar uma melhor distribuição de recursos para atacar este problema.

Com a disponibilização de dados abertos por órgãos como DataSUS, RIPSa e IBGE, torna-se possível explorar esses dados sob diferentes perspectivas. Apesar de já existir indicadores sobre este tema, ainda há espaço para análises mais aprofundadas, especialmente por meio da integração de diferentes fontes de dados e aplicação de técnicas de ciência de dados para identificação de padrões, agrupamentos e possíveis fatores associados à mortalidade por DCNT.

- ii. Há especialista do domínio para ajudar no projeto? Se sim, qual a sua função?

R: *Este projeto não conta com a participação direta de um especialista. No entanto, serão utilizadas fontes oficiais e consolidadas na área da saúde, cujos dados e metodologias já foram validados pelos órgãos governamentais, garantindo confiabilidade aos dados levantados.*

- iii. **Problema de ciência de dados:** defina explicitamente qual é o problema de análise/ciência de dados a ser atacado dentro do contexto de problema/negócio/aplicação descrito.

O problema deste projeto consiste em identificar padrões e perfis de municípios brasileiros em relação à mortalidade por DCNT, a partir da integração de diferentes bases de dados públicas.

De forma mais específica, pretendemos:

- *Analisar a distribuição da mortalidade por DCNT chegando a nível municipal*
- *Identificar agrupamentos de municípios com características semelhantes (clustering);*
- *Explorar possíveis relações entre indicadores de mortalidade e variáveis demográficas.*

O diferencial do projeto está em não apenas descrever os dados, mas aplicar técnicas de ciência de dados para extrair conhecimento novo a partir da combinação de fontes de dados diversas.

2. Fontes de dados

a. Indique a(s) fonte(s) de dados a ser(em) usada(s) e onde estão disponíveis.

Fontes de dados públicas:

- *DataSUS – Dados de mortalidade por causas (CID-10): <https://datasus.saude.gov.br/>*
- *RIPSA – Indicadores consolidados de mortalidade, incluindo DCNT: <https://www.ripsa.org.br/>*
- *IBGE – Dados demográficos e populacionais por município: <https://www.ibge.gov.br>*

b. Necessitará de dados primários e/ou secundários? Comente.

Serão utilizados exclusivamente dados secundários. Isso reduz o tempo de coleta, além de garantir maior abrangência territorial e temporal.

c. Dê exemplos de dados a serem usados.

- *Taxas de mortalidade por DCNT por município (RIPSA/DataSUS)*
- *Número de óbitos por causas específicas (CID-10)*
- *População total por município (IBGE)*
- *Códigos geográficos (IBGE)*
- *Região de saúde e macrorregião (DataSUS)*
- *Percentual de mortalidade por mil habitantes por região demográfica (RIPSA/DataSUS/IBGE)*

d. Há previsão de uso de dados sensíveis? Se sim, justifique.

Não, pois os dados utilizados já foram agregados e anonimizados pelos órgãos que os publicam. Sendo assim, o projeto está em conformidade com a LGPD.

3. Coleta de dados

a. Há necessidade de instrumento de coleta de dados (e.g., formulário)? Se sim, o que se deseja obter com ele?

Não haverá necessidade de coleta de dados primários, uma vez que os dados serão obtidos diretamente de bases públicas por meio de download ou acesso via APIs.

A etapa de coleta consistirá em:

- *Extração de arquivos (CSV/JSON/XML)*
- *Integração entre diferentes bases*
- *Padronização de identificadores (ex: código IBGE)*

4. A proposta está dentro do seu tema de mestrado?

A proposta está alinhada sim com o tema do mestrado, mas não em sua totalidade. Ela tem uma forte relação, mas existem anuências que são particulares para o tema de mestrado e para o projeto da disciplina.

5. Alguma informação ou aspecto adicional específico ao seu trabalho?

O projeto será desenvolvido utilizando a linguagem Python, com uso de bibliotecas voltadas para ciência de dados (como pandas, numpy, DuckDB, entre outras).

As principais etapas incluem:

- *Extração e limpeza de dados (ETL)*
- *Análise exploratória*
- *Aplicação de técnicas de agrupamento (clustering), se cabível*
- *Visualização dos resultados de forma tabular e de gráficos*